Simulación de osciladores mediante redes neuronales hamiltonianas

Introducción

En la física hamiltoniana, describimos el estado de un sistema mediante un conjunto de coordenadas $(\mathbf{q}, \mathbf{p})$, donde $\mathbf{q}$ típicamente denota las posiciones de las partículas, y $\mathbf{p}$ denota los momentos. Luego, definimos una función escalar $\mathcal{H}(\mathbf{q}, \mathbf{p})$, denotada como el *Hamiltoniano* del sistema. Finalmente, la dinámica del sistema se obtiene mediante el sistema de ecuaciones diferenciales:

$$\frac{d\mathbf{q}}{dt} = \frac{\partial \mathcal{H}}{\partial \mathbf{p}}, \quad \frac{d\mathbf{p}}{dt} = -\frac{\partial \mathcal{H}}{\partial \mathbf{q}} \tag{1}$$

En [1], Greydanus et al introducen la idea de una red neuronal hamiltoniana (HNN), una red neuronal diseñada para simular la dinámica de un sistema físico utilizando su hamiltoniano. Lo que diferencia las HNN de otros tipos de redes neuronales es que, en vez de entrenar redes neuronales para aproximar los *valores* de una función dada (por ejemplo, los valores del hamiltoniano), una HNN se entrena para que sus derivadas parciales aproximen las derivadas temporales del sistema dado (es decir, entrenar un modelo que cumpla eq. 1). Concretamente, los datos que utilizamos para entrenar nuestro modelo son de la forma $\left\{p_i, q_i, \frac{dq_i}{dt}, \frac{dp_i}{dt}\right\}_{i=1}^{N}$, donde q_i, p_i son las coordenadas de nuestro sistema en cierto punto, y $\frac{dq_i}{dt}$ $\frac{dp_i}{dt}$ son las derivadas temporales en el mismo punto. Luego, la función de pérdida con la cual entrenamos nuestra red neuronal es:

$$\mathcal{L}_{\text{HNN}} = \left\| \frac{\partial H(q_i, p_i)}{\partial p} - \frac{dq_i}{dt} \right\|_2 + \left\| \frac{\partial H(q_i, p_i)}{\partial q} + \frac{dp_i}{dt} \right\|_2 \tag{2}$$

Donde H denota la red neuronal que estamos entrenando. La idea es que, al minimizar $\mathcal{L}_{\text{HNN}}$, una red neuronal aprenderá a aproximar el hamiltoniano del sistema dado, y tenga una tendencia fuerte a respetar invariantes (como conservación de energía) que estan expresadas implícitamente en eq. 1.

Arquitectura y entrenamiento

Para cada sistema físico, entrenamos dos redes neuronales: una red neuronal hamiltoniana, y una red neuronal tradicional. La red neuronal tradicional se entrenó para predecir las derivadas parciales directamente, es decir, para minimizar la función de pérdida:

$$\mathcal{L}_{\text{TRAD}} = \left\| B(q_i, p_i) - \left(\frac{dq_i}{dt}, \frac{dp_i}{dt} \right) \right\|_2 \tag{3}$$

(Donde B denota la red neuronal tradicional). Ambas redes neuronales tienen la misma arquitectura: Reciben como entrada $2 \times n \times d$ números escalares, donde n es el número de partículas, y d es el número de dimensiones espaciales. Luego, los datos pasan por 2 capas totalmente conectadas, con activación tanh. Finalmente, la HNN devuelve un escalar, y la red neuronal tradicional devuelve $2 \times n \times d$ escalares. Implementamos éstas redes neuronales utilizando la librería `pytorch` [2].

El algoritmo de entrenamiento fue rudimentario: utilizamos el optimizador `pytorch.optim.Adam`, con el parámetro `lr = 1e-3`. Entrenamos ambos modelos por 2000 generaciones.

Oscilador harmónico

El primer sistema que simularemos es el oscilador harmónico simple, donde $\mathcal{H} = \frac{1}{2}kq^2 + \frac{p^2}{2m}$. Para simplificar, tomamos $k = m = 1$ en nuestra simulación. Entonces, tenemos $\mathcal{H} = \frac{1}{2}q^2 + \frac{1}{2}p^2 = E$,

que es la ecuación de un círculo en q y p con radio $\sqrt{2E}$. Para nuestra simulación, usamos trayectorias con $E \in (0.2, 1)$, tomando varias coordenadas de q y p para cada valor de E. En la siguiente gráfica, visualizamos los resultados obtenidos: A la izquierda, mostramos los valores de las coordenadas q y p obtenidas utilizando tando la HNN, y la red neuronal tradicional. Como ha de esperarse, éstos datos aproximan una circunferencia. A la derecha, mostramos el valor de $\sqrt{p^2 + q^2}$. Si las dos simulaciones fuesen perfectas, el gráfico a la derecha tendría 3 líneas horizontales a la misma altura. Sin embargo, podemos ver que la simulación dada por la HNN oscila alrededor del valor correcto, mientras que la red neuronal tradicional comienza cerca del valor correcto, pero luego diverge gradualmente al aumentar el tiempo.

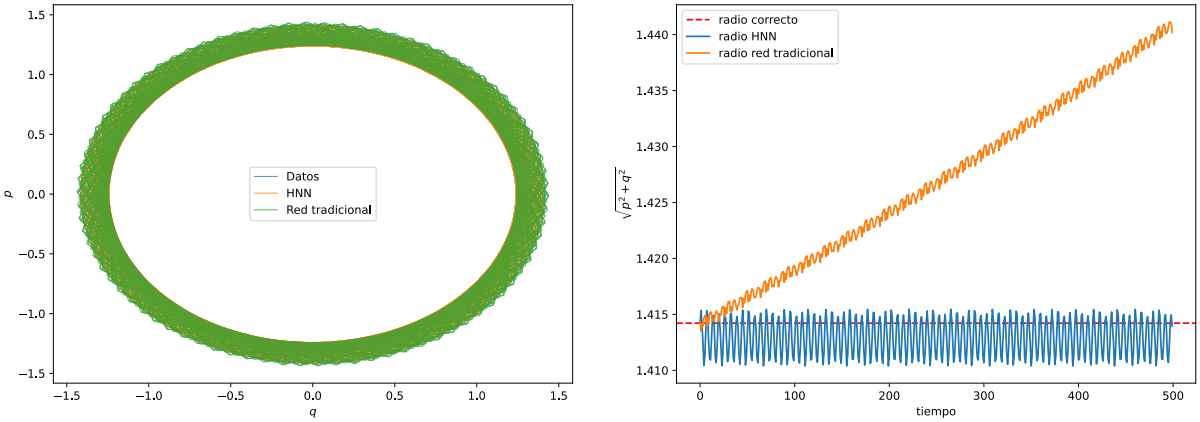

fig. 1: Resultados al ajustar modelos al oscilador harmónico

Mirando brevemente fig. 1, podemos ver que las HNN tienden a aproximar mejor el comportamiento del sistema al simularlo por tiempos más largos (por lo menos, comparado con la simulación más "ingenua" que estamos usando como punto de comparación). Esto es coherente con los resultados encontrados en [1], y parece ser una propiedad general de las HNN, no un artefacto de éste sistema en particular, como veremos más adelante. La razón detrás de ésta ventaja parece ser que, al usar una HNN, H para simular el sistema, estamos utilizando una dinámica dada por:

$$\frac{dq}{dt} = \frac{\partial H}{\partial p} \quad \frac{dp}{dt} = -\frac{\partial H}{\partial q} \tag{4}$$

Lo cual implica que, por construcción, las funciones $q(t)$ y $p(t)$ respetan la conservación de H. (Es decir, $H(\mathbf{q}, \mathbf{p}) \approx H(\mathbf{q}', \mathbf{p}')$). Ahora bien, la conservación del hamiltoniano $\mathcal{H}$ esencialmente expresa la ley de la conservación de la energía, la cual, por el teorema de Noether, es equivalente a la simetría temporal.[1]

En otras palabras, al minimizar $\mathcal{L}_{\text{HNN}}$, la HNN está directamente aprendiendo a respetar la simetría temporal (suponiendo que H es una aproximación razonable de $\mathcal{H}$), mientras que al minimizar $\mathcal{L}_{\text{TRAD}}$, dicha simetría no entra en juego de forma tan directa, razón por la que una HNN es particularmente buena al simular sistemas físicos por tiempos más largos sin desviarse demasiado.

Oscilador de Duffing

La ecuación de Duffing [4] es la ecuación no lineal de segundo orden dada por

$$\ddot{x} - x + \varepsilon x^3 = 0 \tag{5}$$

Tomando $\varepsilon = 1$, el hamiltoniano que describe dicho sistema es:

[1] Landau mostró en [3] que la conservación de la energía se deriva de la homogeneidad temporal, aunque no menciona directamente el teorema de Noether

$$\mathcal{H} = \frac{p^2}{2} - \frac{q^2}{2} + \frac{q^4}{4} \tag{6}$$

Por supuesto, el sistema con éste hamiltoniano está restringido a moverse en regiones donde $\mathcal{H}$ es constante.

En fig. 2 mostramos las curvas de nivel de $\mathcal{H}$. Como podemos ver, hay tres regiones relevantes, denotadas por los colores azul, amarillo y rojo en el diagrama. Cuando $\mathcal{H} < 0$ (región azúl), la partícula está atrapada en uno de los dos pozos centrados en $q = \pm 1$, mientras que con $\mathcal{H} > 0$, la partícula tiene suficiente energía para pasar de un pozo al otro. Cuando $\mathcal{H} = 0$, vemos que la energía es *exáctamente* la mínima energía necesaria para que la partícula pase de un pozo al otro.

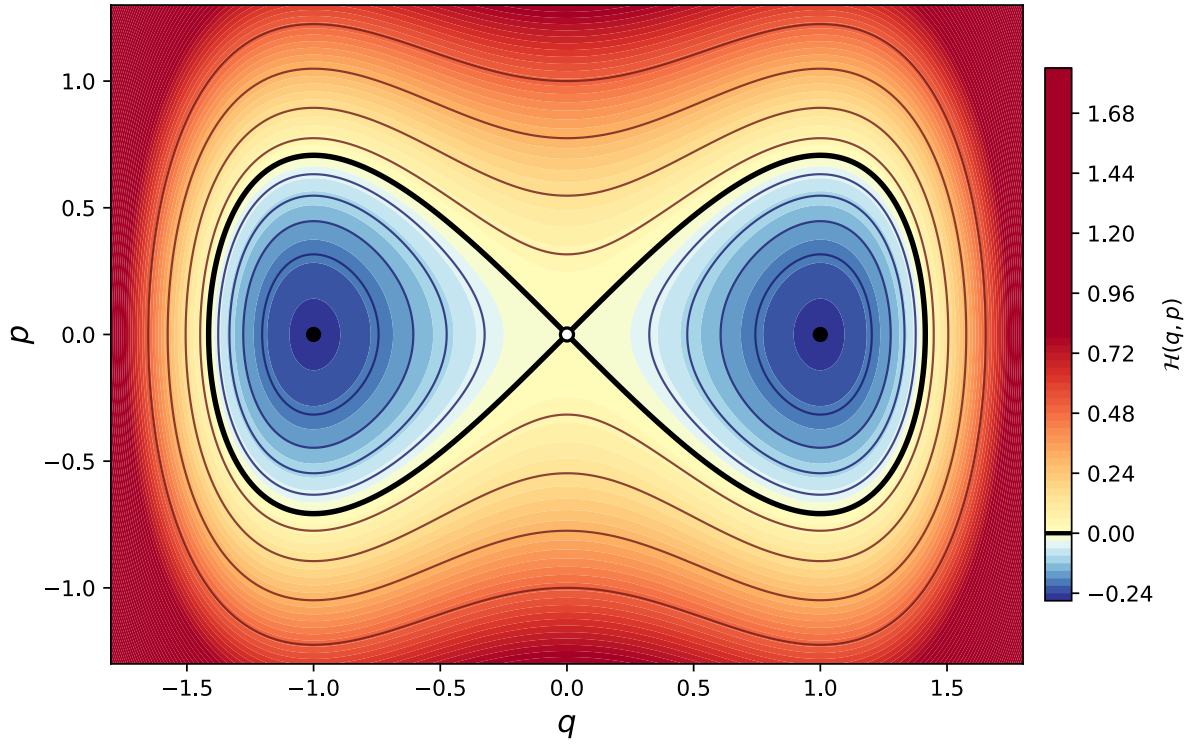

fig. 2: Curvas de nivel de $\mathcal{H}$ para el oscilador de Duffing

Simulamos dicho sistema integrando las funciones $\frac{dq}{dt} = p$ y $\frac{dp}{dt} = q - q^3$ numéricamente utilizando `scipy.integrate.solve_ivp` para obtener $q(t)$ y $p(t)$. Utilizamos los datos generados de ésta forma para entrenar las dos redes neuronales, y luego para compararlas (entre más cercana sea la trayectoria la obtenida usando `solve_ivp`, mejor).

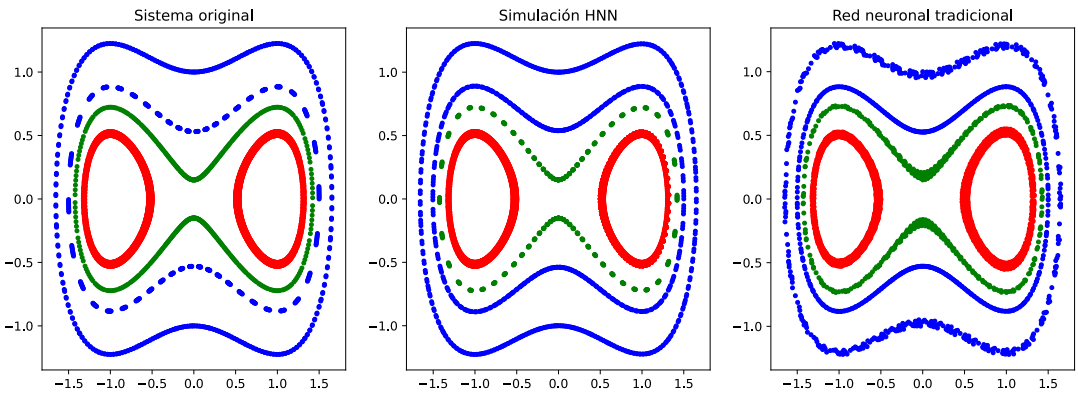

fig. 3: Coordenadas del oscilador de Duffing

Podemos ver que tanto la HNN como la red neuronal tradicional respetan las tres regiones que mostramos anteriormente. Sin embargo, también es claro que la simulación que utiliza la HNN es más precisa que la simulación hecha con una red neuronal tradicional.

Para tener una mejor impresión de la dinámica dada por la HNN, podemos, de nuevo, graficar las curvas de nivel de la HNN, como hicimos con el hamiltoniano $\mathcal{H}$ en fig. 2:

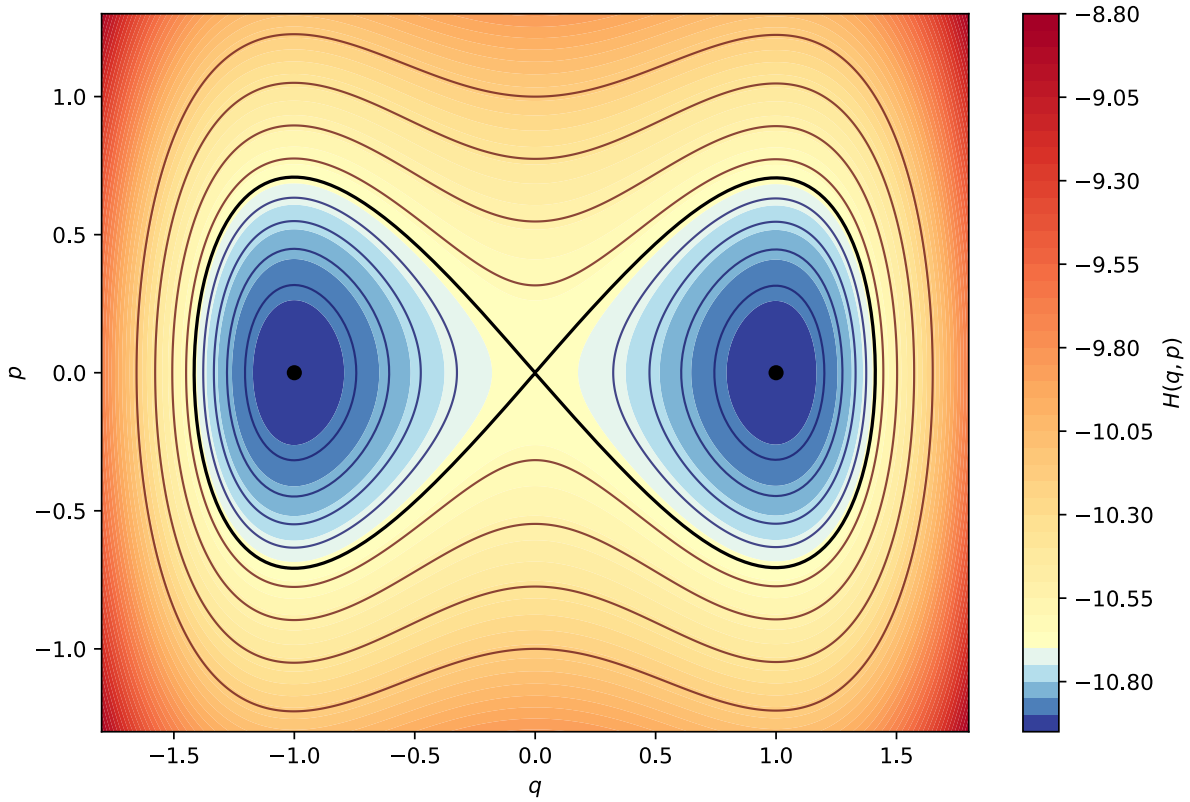

Comparando fig. 2 y fig. 4, podemos ver de nuevo que la HNN entrenada tiene la misma estructura que el hamiltoniano del oscilador. Algo que podemos notar es que los valores escalares de la HNN están en un rango distinto que los del hamiltoniano. Parece que la HNN aprendió la aproximación $H \approx \mathcal{H} - 10.6842$. Dado que la dinámica de la partícula está determinada por los gradientes de $\mathcal{H}$ (y aproximadamente determinada por los gradientes de H), éste cambio no afecta la aproximación.

Sistema Hénon-Heiles

En [5], Michael Hénon y Carl Heiles introducen el sistema Hénon-Heiles para describir las dinámicas de las estrellas de una galaxia. En dos dimensiones, el potencial de éste sistema se puede expresar como:

$$U(x) = \frac{1}{2}(x^2 + y^2) + \lambda\left(x^2 y - \frac{y^3}{3}\right) \tag{7}$$

Tomando $\lambda = 1$, y usando las coordenadas $q_1 = x$, $q_2 = y$, $p_1 = \dot{x}$, $p_2 = \dot{y}$ el hamiltoniano del sistema Hénon-Heiles es:

$$\mathcal{H} = \frac{1}{2}(p_1^2 + p_2^2) + \frac{1}{2}(q_1^2 + q_2^2) + \left(q_1^2 q_2 - \frac{q_2^3}{3}\right) \tag{8}$$

Debido a la alta dimensionalidad de éste problema (se trata de una partícula en 2 dimensiones, por lo tanto el estado está determinado por 4 coordenadas), no es posible visualizar el estado completo del sistema. Nos restringimos a mostrar gráficos separados de las trayectorias de las posiciones y los momentos al simular éste sistema usando un HNN y una red neuronal más tradicional.

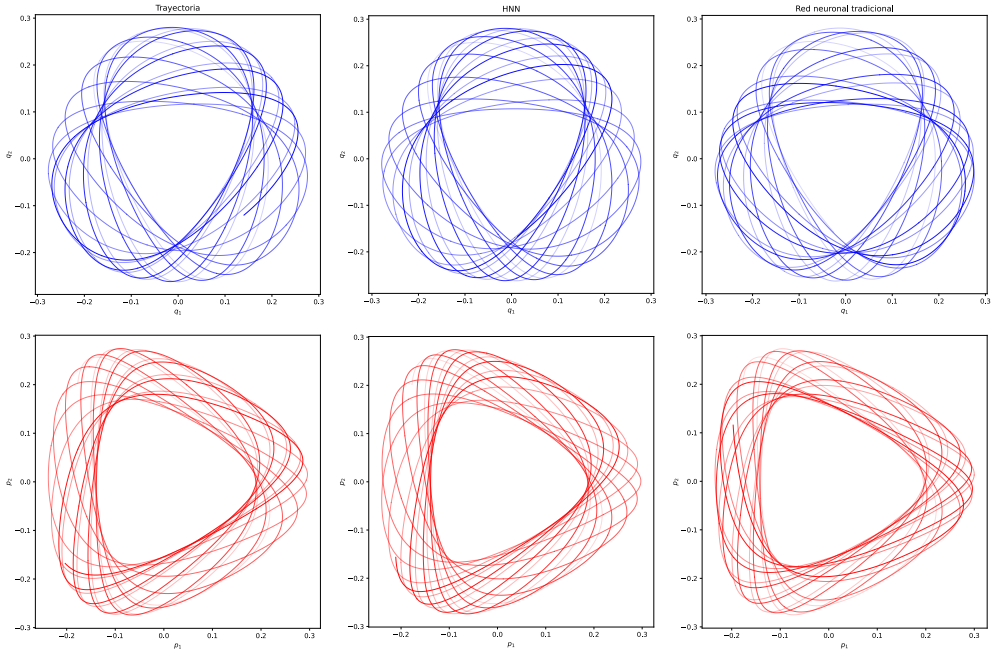

Aquí, es menos visible cuál de las redes neuronales logró la mejor aproximación de la trayectoria real, por un lado debido a la susodicha dimensionalidad del sistema, pero también en parte debido a que hemos simulado el sistema por un periodo de tiempo relativamente corto. Si alargamos el período de tiempo obtenemos:

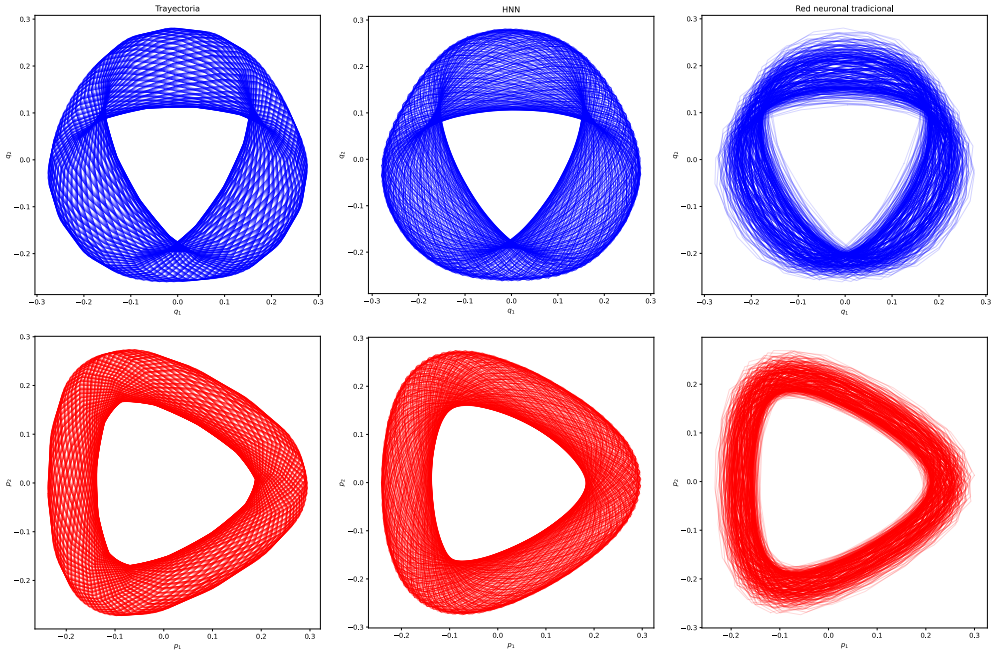

Donde sí comiena a ser visible que la HNN da una mejor aproximación al sistema. Como ya mencionamos, una de las ventajas principales de las HNN es jústamente el hecho de que pueden dar una buena simulación a lo largo de períodos de tiempo relativamente largos.

Finalmente, la simulación más larga que hicimos da los siguientes resultados:

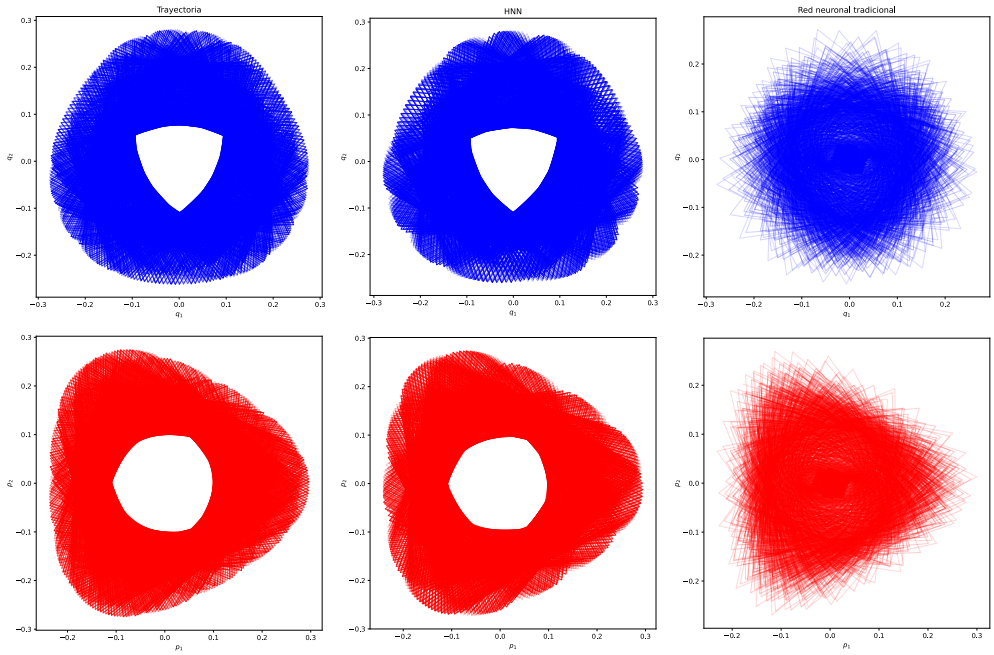

En el sistema físico, las coordenadas $\mathbf{q}$ y $\mathbf{p}$ núnca se acercan al origen debido a conservación de energía: el hecho de que el sistema tiene energía distinta de cero prohibe $\mathbf{q} = \mathbf{p} = \mathbf{0}$. Parece ser que la red neuronal tradicional es incapaz de respetar la conservación de energía, y exhibe un fenómeno análogo a "disipación", es decir, que pierde energía en función del tiempo, a pesar de estar simulando un sistema sin disipación.

Bibliografía

[1] Sam Greydanus, Misko Dzamba, and Jason Yosinski, "Hamiltonian Neural Networks." [Online]. Available: https://arxiv.org/abs/1906.01563

[2] Adam Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library." [Online]. Available: https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf

[3] L. D. Landau and E. M. Lifshitz, "Mechanics." Butterworth-Heinemann, 1976.

[4] S. H. Strogatz, *Nonlinear Dynamics and Chaos: With Applications to Physics, Biology, Chemistry, and Engineering*, 2nd ed. Westview Press, 2015.

[5] M. Hénon and C. Heiles, "The applicability of the third integral of motion: Some numerical experiments," *The Astronomical Journal*, vol. 69, pp. 73–79, 1964, doi: 10.1086/109234.